

Сходимость с оценкой вероятностей больших  
отклонений для задач выпуклой оптимизации и  
седловых задач в условиях повышенной  
гладкости

Выпускная квалификационная работа бакалавра

Рубцов Денис Николаевич

Научный руководитель: д.ф.-м.н. А. В. Гасников

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 03.03.01 Прикладные математика и физика

2025

# Сходимость с оценкой вероятностей больших отклонений

## Цели

1. разработать быстрые алгоритмы для решения задач выпуклой стохастической оптимизации, обеспечивающие сходимость с высокой вероятностью
2. исследовать эти алгоритмы с помощью теоретического анализа и вычислительных экспериментов

# Сходимость с высокой вероятностью

Задача стохастической оптимизации

$$\min_{x \in \mathbb{R}^d} f(x) := \mathbb{E}f(x, \xi), \quad \xi \sim \mathcal{P}$$

Как правило, результатом стохастических градиентных методов является точка  $x_\varepsilon$  такая, что

$$\mathbb{E}f(x_\varepsilon) - \min f \leq \varepsilon$$

Мы рассматриваем алгоритмы, результатом которых являются точки  $x_{\varepsilon,p}$ , удовлетворяющие условию

$$P\{f(x_{\varepsilon,p}) - \min f \leq \varepsilon\} \geq 1 - p$$

$$\Updownarrow$$

$$P\{f(x_{\varepsilon,p}) - \min f \geq \varepsilon\} \leq p$$

# Наивный подход

## Наивное решение

Если решить задачу  $\mathbb{E}f(x_\varepsilon) - \min f \leq p\varepsilon$ , то желаемое неравенство  $P\{f(x_{\varepsilon,p}) - \min f \leq \varepsilon\} \geq 1 - p$  следует автоматически по неравенству Маркова.

## Проблема

Сложность решения задачи сходимости по матожиданию, обычно, порядка  $\mathcal{O}(\frac{1}{\varepsilon})$ . Тогда сложность наивного решения задачи сходимости с высокой вероятностью  $\mathcal{O}(\frac{1}{p\varepsilon})$ .

## Хочется

уменьшить множитель  $\frac{1}{p}$  до  $\log(\frac{1}{p})$

# Ключевая идея №1 : Robust distance estimation (RDE)

Пусть имеется  $m$  точек  $x_1, \dots, x_m$ , для которых  $\mathbb{E}x_i - x^* \leq \frac{\varepsilon}{3}$ , т.е.  $P[\|x - x^*\| \leq \varepsilon] \geq \frac{2}{3}$ . Тогда среди этих точек можно выбрать такую  $x_{i^*}$ , вокруг которой «группируются» остальные точки.


Theorem (Nemirovskiy, Yudin, 1983 <sup>a</sup>)

Точка  $x_{i^*}$ , возвращаемая алгоритмом RDE удовлетворяет условию

$$P(\|x_{i^*} - x^*\| \leq 3\varepsilon) \geq 1 - e^{-\frac{m}{18}}$$

---

<sup>a</sup>Nemirovskij A.S., Yudin D.B.  
Problem complexity and method efficiency in optimization. - 1983.



## Применение RDE для обеспечения сходимости с высокой вероятностью: описание подхода

$$\frac{\mu}{2} \|x - x^*\|^2 \leq f(x) - f(x^*) \leq \frac{L}{2} \|x - x^*\|^2$$

Пусть мы имеем точки  $x_i$  ( $i = 1, \dots, m$ ) такие, что

$$\mathbb{E}f(x_i) - \min f \leq \frac{\varepsilon}{3} \xrightarrow{\text{неравенство Маркова}}$$

$$P(f(x_i) - f^* \leq \varepsilon) \geq \frac{2}{3} \xrightarrow{\text{сильная выпуклость}}$$

$$P(\|x_i - x^*\| < \sqrt{\frac{2\varepsilon}{\mu}} =: \delta) \geq \frac{2}{3} \xrightarrow{\text{RDE}}$$

$$P(\|x_{i^*} - x^*\| < 3\delta) \geq 1 - e^{-\frac{m}{18}} \xrightarrow{\text{гладкость}}$$

$$P(f(x_{i^*}) - f^* \leq 9\frac{L}{\mu}\varepsilon) \geq 1 - e^{-\frac{m}{18}}$$

## Применение RDE для обеспечения сходимости с высокой вероятностью: проблема

$$\mathbb{E}f(x_i) - \min f \leq \frac{\varepsilon}{3} \implies$$

$$P(f(x_{i^*}) - f^* \leq 9\frac{L}{\mu}\varepsilon) \geq 1 - e^{-\frac{m}{18}} = 1 - p$$

При  $m \sim \log(1/p)$  получаем логарифмическую зависимость от  $p$  сложности решения задачи сходимости с высокой вероятностью. Однако, точность решения ухудшается в  $\kappa$  раз, где число обусловленности  $\kappa = \frac{L}{\mu} \gg 1$  может быть достаточно большим!

## Ключевая идея №2: Проксимальный метод

Как бороться с зависимостью от числа обусловленности  $\kappa$ ?

Последовательно решать регуляризованные подзадачи:

$$\bar{x}_{i+1} := \arg \min_x \left\{ f^i(x) := f(x) + \frac{\lambda_i}{2} \|x - x_i\|^2 \right\}$$

1) Выбираем параметры растущими геометрически:  $\lambda_i = \mu \cdot 2^i$ .

2) **Эффект:** Новая функция  $f^i$  становится хорошо обусловленной.

$$\kappa_i = \frac{L + \lambda_i}{\mu + \lambda_i} = \mathcal{O}(1), \quad i > \log \frac{L}{\mu}$$

3) При этом решение новых задач будет приближенным решением основной задачи

$$f(x_{j+1}) - f^* \leq (f^j(x_{j+1}) - f^j(\bar{x}_{j+1})) + \sum_{i=0}^j \frac{\lambda_j}{2} \|\bar{x}_i - x_i\|^2.$$



# Основной алгоритм и его сложность

## Алгоритм proxBoost

Комбинация RDE и проксимального метода позволяет получить решение  $x_T$  такое, что:

$$P\{f(x_T) - \min f \leq \varepsilon\} \geq 1 - p$$

## Об оракульной сложности

Все дальнейшие результаты будут выражены в терминах сложности  $\mathcal{C}_{\mathcal{M}}(f, \varepsilon)$  оракула  $\mathcal{M}(f, \varepsilon)$ , возвращающего точку  $x_\varepsilon$  такую, что  $\mathbb{E}f(x_\varepsilon) - \min f \leq \varepsilon$ .

# Сложность алгоритма proxBoost

Theorem (Davis, Drusvyatskiy, 2021<sup>1</sup>)

Сложность алгоритма *proxBoost*, решающего задачу  $P\{f(x_{\epsilon,p}) - \min f \leq \epsilon\} \geq 1 - p$ , для  $\mu$ -сильно выпуклых  $L$ -гладких функций:

$$\mathcal{O} \left( \underbrace{\log \left( \frac{\log \kappa}{p} \right) \log(\kappa)}_{\text{Доплата}} \cdot \mathcal{C}_{\mathcal{M}} \left( f, \frac{\epsilon}{\log \kappa} \right) \right)$$

**Вывод:** Доплата за сходимость с высокой вероятностью является логарифмической по параметрам задачи.

---

<sup>1</sup>From low probability to high confidence in stochastic convex optimization / D.Davis et al // JMLR - 2021

## Метод сглаживания

На гладкий и негладкий случай можно смотреть единообразно:

Функция  $f$  -  $(L, \gamma)$ -гладкая, если

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2 + \gamma. \quad (1)$$

Если функция негладкая, но  $M$ -липшицева, то есть

$$\|\nabla f(y) - \nabla f(x)\| \leq M,$$

то (1) выполняется при

$$L = \frac{M^2}{2\gamma}$$

# Сложность алгоритма в негладком случае

## Theorem (Рубцов, 2025)

Сложность обобщенного алгоритма *proxBoost* для негладких  $\mu$ -сильно выпуклых функций, решающего задачу

$P\{f(x_{\varepsilon,p}) - \min f \leq \varepsilon\} \geq 1 - p$ :

$$\mathcal{O} \left( \log \left( \frac{1}{p} \right) \log \left( \frac{M^2}{\mu \varepsilon} \right) \cdot \mathcal{C}_{\mathcal{M}} \left( f, \frac{\varepsilon}{\log \left( \frac{M^2}{\mu \varepsilon} \right)} \right) \right).$$

# Метод регуляризации для решения не сильно выпуклых задач

## Theorem

*Пусть функция  $f(x)$  выпукла. Будем решать задачу минимизации функции*

$$f^\mu(x) = f(x) + \frac{\mu}{2} \|x - x_0\|^2,$$

*где  $\mu \sim \frac{\varepsilon}{R^2}$ ,  $R = \|x^* - x_0\|$ .*

*Пусть мы нашли точку  $x$  такую, что*

$$f^\mu(x) - \min f^\mu < \frac{\varepsilon}{2}$$

*Тогда*

$$f(x) - \min f < \varepsilon$$

# Сложность алгоритма proxBoost в выпуклом случае

## Theorem (Рубцов, 2024)

Сложность обобщенного алгоритма proxBoost для **выпуклых**  $L$ -гладких функций, решающего задачу

$P\{f(x_{\varepsilon,p}) - \min f \leq \varepsilon\} \geq 1 - p$ :

$$\mathcal{O} \left( \log\left(\frac{1}{p}\right) \log \frac{LR^2}{\varepsilon} \cdot \mathcal{C}_{\mathcal{M}}\left(f, \frac{\varepsilon}{\log \frac{LR^2}{\varepsilon}}\right) \right).$$


## Обобщение на разные классы задач

Важно отметить, что предложенный подход является «оберткой» над методами и работает для разных классов функций.

Класс функции	Итоговая оракульная сложность
сильно выпуклая, гладкая	$\log\left(\frac{1}{\rho}\right) \log(\kappa) \cdot \mathcal{C}_{\mathcal{M}}\left(f, \frac{\epsilon}{\log \kappa}\right)$
сильно выпуклая, негладкая	$\log\left(\frac{1}{\rho}\right) \log\left(\frac{M^2}{\mu\epsilon}\right) \cdot \mathcal{C}_{\mathcal{M}}\left(f, \frac{\epsilon}{\log\left(\frac{M^2}{\mu\epsilon}\right)}\right)$
выпуклая, гладкая	$\log\left(\frac{1}{\rho}\right) \log \frac{LR^2}{\epsilon} \cdot \mathcal{C}_{\mathcal{M}}\left(f, \frac{\epsilon}{\log \frac{LR^2}{\epsilon}}\right)$
выпуклая, негладкая	$\log\left(\frac{1}{\rho}\right) \log\left(\frac{MR}{\epsilon}\right) \cdot \mathcal{C}_{\mathcal{M}}\left(f, \frac{\epsilon}{\log\left(\frac{MR}{\epsilon}\right)}\right)$

# Результаты: График сходимости

## SGD vs ProxBoost



Ошибка  $f(x) - f^*$  от количества вызовов оракула. Сплошная линия — медиана, область — 25-75% квантили.

**SGD, обернутый в proxBoost (синий цвет), демонстрирует более надежную сходимость, чем SGD (красный).**



## Выносятся на защиту

1. **Универсальный мета-алгоритм** для преобразования сходимости по матожиданию в сходимость с высокой вероятностью.
2. **Новые оценки сложности** для широкого класса задач, включая негладкие и не сильно выпуклые случаи.
3. **Экспериментальное подтверждение** эффективности и надежности предложенного подхода.